

METAHEURÍSTICAS

2024-2025



- Tema 1. Introducción a las Metaheurísticas
- Tema 2. Modelos de Búsqueda: Entornos y Trayectorias vs Poblaciones
- Tema 3. Metaheurísticas Basadas en Poblaciones
- Tema 4: Algoritmos Meméticos
- Tema 5. Metaheurísticas Basadas en Trayectorias
- Tema 6. Metaheurísticas Basadas en Adaptación Social
- Tema 7. Aspectos Avanzados en Metaheurísticas
- Tema 8. Metaheurísticas Paralelas
- Tema 9. Modelos de IA Evolutivos. Aprendizaje Evolutivo

METAHEURÍSTICAS

TEMA 4. ALGORITMOS MEMÉTICOS

- ¿Qué es un Algoritmo Memético?
- ¿Por qué hibridar? Los límites de los Algoritmos Evolutivos
- Algoritmos Meméticos: Introducción
- Sobre el Diseño de Algoritmos Meméticos
- Conclusiones

Bibliografía

- P. Moscato, C. Cotta, "A Gentle Introduction to Memetic Algorithms" . In: F. Glover, G.A. Kochenberger, (Eds.). Handbook of Metaheuristics. Kluwer Academics. (2003) 105-144, Kluwer, Boston MA, 2003.
- P. Moscato, C. Cotta, Una Introducción a los Algoritmos Meméticos. Inteligencia Artificial 19 (2003) 131-148.

ALGORITMOS MEMÉTICOS

SUMARIO

- **¿Qué es un Algoritmo Memético?**
- **¿Por qué hibridar? Los límites de los Algoritmos Evolutivos**
- **Algoritmos Meméticos: Introducción**
- **Sobre el Diseño de Algoritmos Meméticos**
- **Conclusiones**

¿Qué es un Algoritmo Memético?

Algoritmo basado en la evolución de poblaciones que para realizar búsqueda heurística intenta utilizar todo el conocimiento sobre el problema
(usualmente conocimiento en términos de algoritmos específicos de búsqueda local para el problema)

¿Por qué esta hibridación?

ALGORITMOS MEMÉTICOS

SUMARIO

- **¿Qué es un Algoritmo Memético?**
- **¿Por qué hibridar? Los límites de los Algoritmos Evolutivos**
- **Algoritmos Meméticos: Introducción**
- **Sobre el Diseño de Algoritmos Meméticos**
- **Conclusiones**

¿Por qué hibridar?

Los límites de los AEs


❑ Algoritmos evolutivos →
son buenos
exploradores

❑ Algoritmos de →
búsqueda local son
malos exploradores

❑ Algoritmos evolutivos
son malos explotadores




❑ Algoritmos de búsqueda
local son buenos
explotadores ●



¿Por qué hibridar?

Los límites de los AEs

Sobre el Comportamiento de los Algoritmos Evolutivos



¿Por qué hibridar?

Los límites de los AEs

No Free Lunch Theorem (1995):

"...for any algorithm, any elevated performance over one class of problems is exactly paid for in performance over another class." **Wolpert and Macready (1997)**

$$\sum_f E(\vec{c} / f, m, a) = \sum_f E(\vec{c} / f, m, b)$$



David. H. Wolpert



William G. Macready

No free lunch theorems for optimization

Wolpert, D.H.; Macready, W.G.;


Evolutionary Computation, IEEE Transactions on 1:1, April 1997, 67 – 82

¿Por qué hibridar?

Los límites de los AEs

Implicaciones
de NFL (I)


$$\sum_f E(\vec{c} / f, m, a) = \sum_f E(\vec{c} / f, m, b)$$



¿Por qué hibridar?

Los límites de los AEs

Implicaciones de NFL (II): Ganar en un cierto dominio implica perder en los restantes




¿Por qué hibridar?

Los límites de los AEs

Discusión


¿La búsqueda aleatoria se comporta como nuestro algoritmo?

¡Hay que discutir algunas cuestiones en el teorema de NFL!



¿Por qué hibridar?

Los límites de los AEs




¿Por qué hibridar?

Los límites de los AEs

Consideremos los diferentes grados de conocimiento del problema:

1. Conocimiento perfecto
2. Conocimiento parcial
3. Poco conocimiento
4. Muy poco conocimiento
5. Ningún conocimiento



(NFL)

Los resultados del teorema NFL son críticos tanto en cuanto (2) es comparado con (5).

¿Por qué hibridar?

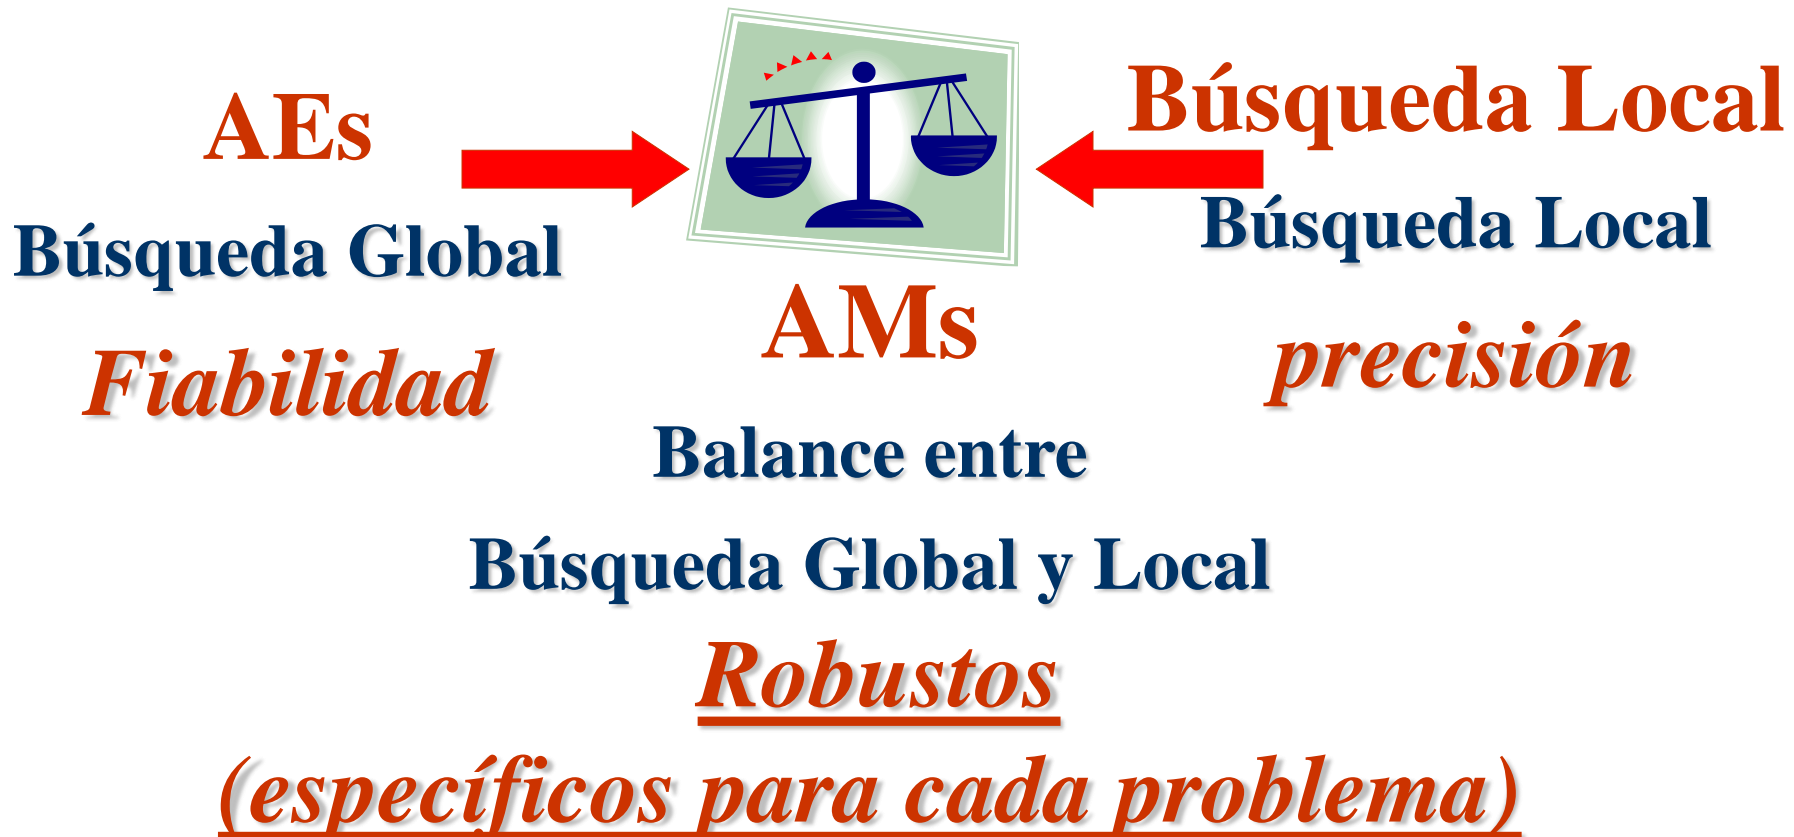
Los límites de los AEs

Los AEs pueden mejorar su comportamiento con conocimiento

- El conocimiento sobre el problema debe ser incluido en el algoritmos de búsqueda.
- Lawrence Davis resaltó esta aproximación a finales de los 80 y primeros de los 90:
 - Utilizó representación del problema **ad-hoc**.
 - **Introdujo heurísticas** específicas del problema en los AEs. Se obtiene un **AE híbrido**.
- Usualmente, las heurísticas específicas son algoritmos de búsqueda local.

¿Por qué hibridar?

Los límites de los AEs



ALGORITMOS MEMÉTICOS

SUMARIO


- **¿Qué es un Algoritmo Memético?**
- **¿Por qué hibridar? Los límites de los Algoritmos Evolutivos**
- **Algoritmos Meméticos: Introducción**
- **Sobre el Diseño de Algoritmos Meméticos**
- **Conclusiones**

Algoritmos Meméticos

- Los **Algoritmos Meméticos** (AMs) se construyen sobre la noción de *meme*.
- Significado: Unidad de imitación, análoga a un gen pero en el contexto de la "evolución cultural"
- El Término fue introducido por Richard Dawkins en el libro "The Selfish Gene" ("El Gen Egoísta") (University Press, 1976)




Algoritmos Meméticos



«Examples of **memes** are tunes, ideas, catch-phrases, clothes fashions, ways of making pots or of building arches. Just as genes propagate themselves in the gene pool by leaping from body to body via sperms or eggs, so **memes** propagate themselves in the **meme pool** by leaping from brain to brain via a process which, in the broad sense, can be called imitation.»

R. Dawkins, 1976

Algoritmos Meméticos



«Ejemplos de **memes** son melodías, ideas, frases hechas, modas en la vestimenta, formas de hacer vasijas, o de construir bóvedas. Del mismo modo que los genes se propagan en el acervo genético a través de gametos, los “**memes**” se propagan en el acervo memético saltando de cerebro a cerebro en un proceso que, en un amplio sentido, puede denominarse imitación.»

R. Dawkins, 1976

Algoritmos Meméticos



A **Memetic Algorithm** is a population of **agents** that alternate periods of **self-improvement** (via local search) with periods of **cooperation** (via recombination), and **competition** (via selection).

P. Moscato, 1989

Moscato, P.A. (1989). On Evolution, Search, Optimization, Genetic Algorithms and Martial Arts: Towards Memetic Algorithms. Caltech Concurrent Computation Program Report 826, Catech, Pasadena, California.

Algoritmos Meméticos

TERMINOLOGÍA EN ALGORITMOS MEMÉTICOS

- En los **Algoritmos Meméticos** se utiliza el término de agentes en lugar de individuos ya que se consideran una extensión de los segundos.
- Tanto la selección como la actualización (reemplazo), son procesos puramente competitivos.
- La reproducción es la encargada de crear nuevos agentes (cooperación). Aunque puede aplicarse una gran variedad de operadores de reproducción, existen básicamente dos: Recombinación y Mutación.

Algoritmos Meméticos

TERMINOLOGÍA EN ALGORITMOS MEMÉTICOS


- Recombinación: Realiza el proceso de cooperación.

Crea nuevos agentes utilizando principalmente la información extraída de los agentes recombinados.

Se suele hablar de combinación inteligente de información.

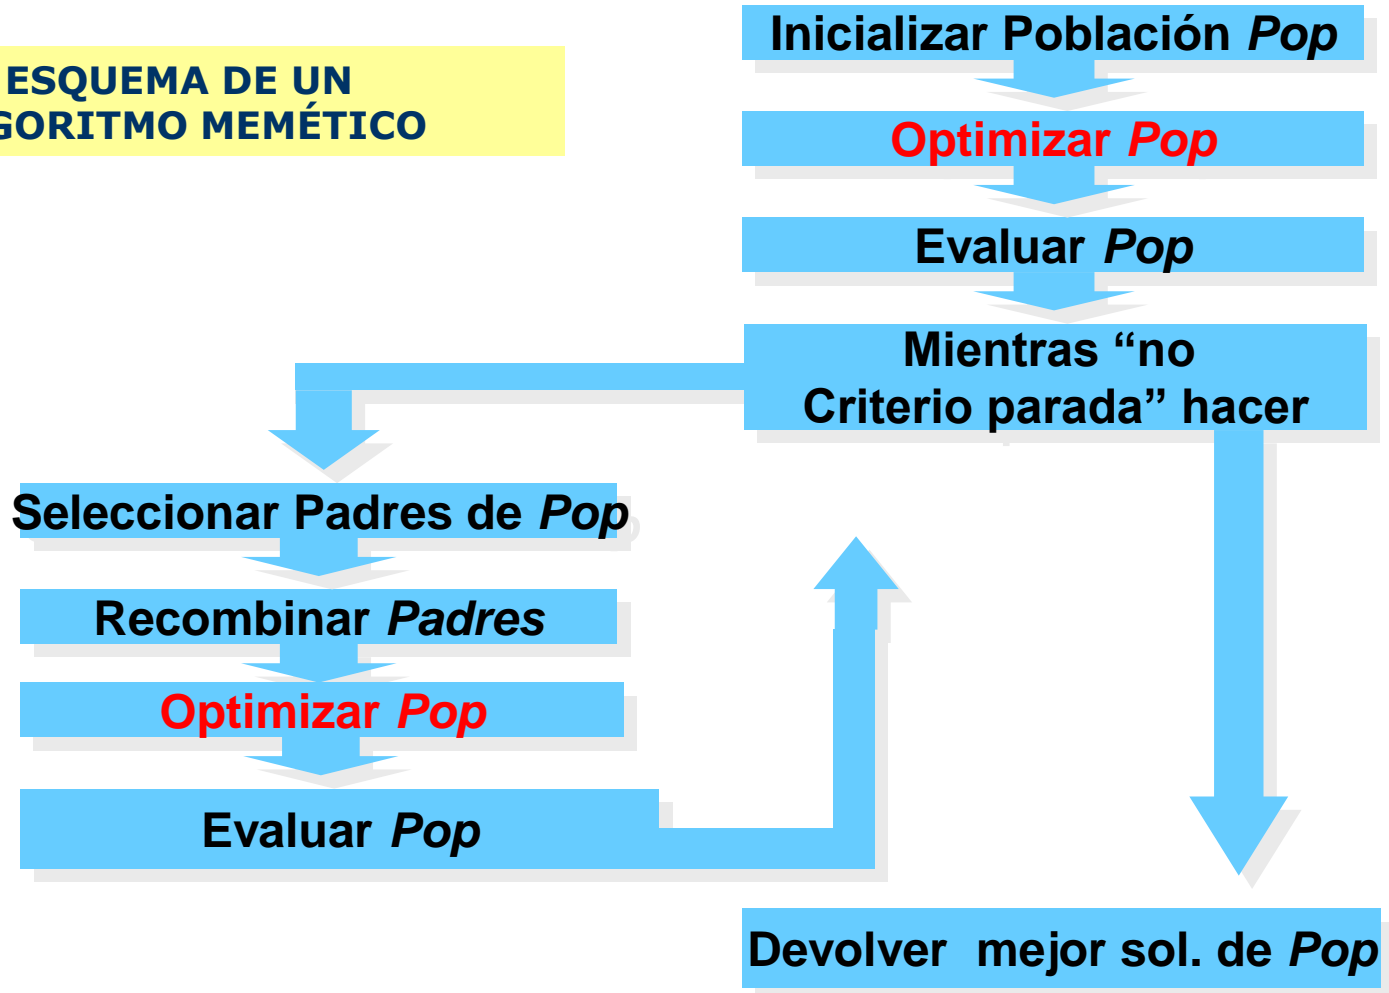
- Mutación: Permite incluir información externa creando nuevos agentes mediante modificación parcial del agente mutado.

Algoritmos Meméticos



Algoritmos Meméticos

ESQUEMA DE UN ALGORITMO MEMÉTICO





Algoritmos Meméticos

OBJETIVO: ¡Ir con los mejores!




Algoritmos de Búsqueda Local



- Tabu search
- Simulated annealing
- ...



Fase de búsqueda independiente



Fase de búsqueda sincronizada



ALGORITMOS MEMÉTICOS

SUMARIO

- ¿Qué es un Algoritmo Memético?
- ¿Por qué hibridar? Los límites de los Algoritmos Evolutivos
- Algoritmos Meméticos: Introducción
- **Sobre el Diseño de Algoritmos Meméticos**
- Conclusiones

Sobre el diseño de Algoritmos Meméticos

- Cuando se aborda el diseño de un AM efectivo para un cierto problema, hay que partir de la base de que no existe un procedimiento sistemático para tal fin (de lo contrario entraría en conflicto con los resultados del Teorema NFL).
- Únicamente pueden considerarse heurísticas de diseño, que probablemente resultarán en un AM efectivo, pero que obviamente no lo pueden garantizar.

Sobre el diseño de Algoritmos Meméticos

- ¿Cuándo se aplica el Algoritmo de Búsqueda Local?
- ¿Sobre qué agentes se aplica?
- ¿Qué uso se hace del agente optimizado?
- ¿Cómo se aplica el optimizador local? (Intensidad de la aplicación)
- Uso de conocimiento: Otras hibridaciones
- ¿Qué Algoritmo de Búsqueda Local se utiliza?
Depende del problema a optimizar

Sobre el diseño de Algoritmos Meméticos

¿Cuándo y sobre qué agentes se aplica?

- Los optimizadores locales, considerados como un operador más, pueden aplicarse de diferentes formas:
 - En la fase de inicialización de la población
 - En cada generación o cada cierto número de ellas
 - Como fin del ciclo reproductivo o durante los operadores de recombinación
 - ...

NOTA: Para que un algoritmo híbrido sea considerado AM, la Búsqueda Local siempre debe aplicarse dentro del proceso evolutivo.

Sobre el diseño de Algoritmos Meméticos

¿Cuándo y sobre qué agentes se aplica?

- A toda la población, o
- sólo a un subconjunto de ella
 - sobre el mejor.
 - sobre representantes de clases tras un proceso de agrupación).
 - Se puede utilizar una probabilidad de actuación de la búsqueda local.
- Sobre los agentes resultantes de la reproducción o sobre los agentes de la población globalmente.
- ...

Sobre el diseño de Algoritmos Meméticos

¿Qué uso se hace del agente optimizado?

Dos modelos (clásicos)

■ Lamarkiano

- El agente resultante del proceso de optimización local se introduce en la población (cede su genotipo) y reemplaza en la población al agente sobre el que se inició el proceso o al más cercano.

■ Baldwiniano

- El agente inicial del proceso de optimización local recibe el fitness del agente final pero no su genotipo (cede su fitness)

Sobre el diseño de Algoritmos Meméticos

¿Cómo se aplica el optimizador local?

- Al aplicar los optimizadores locales, es esencial regular adecuadamente el equilibrio entre
 - anchura (**frecuencia de aplicación del optimizador**)
(uso de probabilidad de actuación de la Búsqueda Local: p_{LS})
 - profundidad (**intensidad del optimizador**)
 - AMs baja intensidad (pocas iteraciones del optimizador local/alta frecuencia)
 - AMs alta intensidad (muchas iteraciones del optimizador local/baja frecuencia)

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63.




Figure 3: Example of LS chain. p_{i+1} is the final parameter value reached by the LS algorithm when it started with a value of p_i . p_0 is the default value for the strategy parameter

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63

Every time the LS algorithm is applied to refine a particular chromosome, a fixed LS intensity should be considered for it, which will be called *LS intensity stretch* (I_{str}). In this way, a LS chain formed throughout n_{app} LS applications and started from solution s_0 will return the same solution as the application of the continuous LS algorithm to s_0 employing $n_{app} \cdot I_{str}$ fitness function evaluations.

After the LS operation, the parameters that define the current state of the LS processing are stored along with the reached final individual (in the steady-state GA population). When this individual is latter selected to be improved, the initial values for the parameters of the LS algorithm will be directly available. For example, if we employ the Solis and Wets' algorithm as LS algorithm, the stored strategy parameter may be the current value of the p parameter. For the more elaborate CMA-ES, the state of the LS operation may be defined by the covariance matrix (C), the mean of the distribution ($\sim m$), the size (σ), and some additional variables used to guide the adaptation of these parameters.

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63

1. Generate the initial population.
2. Perform the steady-state GA throughout n_{freq} evaluations.
3. Build the set S_{LS} with those individuals that potentially may be refined by LS.
4. Pick the best individual in S_{LS} (Let's c_{LS} to be this individual).
5. if c_{LS} belongs to an existing LS chain then
6. Initialise the LS operator with the LS state stored together with c_{LS} .
7. else
8. Initialise the LS operator with the default LS state.
9. Apply the LS algorithm to c_{LS} with an LS intensity of I_{str} (Let's c_{LS}^r to be the resulting individual).
10. Replace c_{LS} by c_{LS}^r in the steady-state GA population.
11. Store the final LS state along with c_{LS}^r .
12. If (not termination-condition) go to step 2.

Figure 4: Pseudocode algorithm for the proposed MACO model

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63

MA-LSCh-CMA

Steady-state GA.

BLX- α .

Negative Assortative Mating.

BGA Mutation Operator.

Standard replacement strategy

CMA-ES as Continuous LS algorithm.



Figure 5: BLX- α

Hansen, N. and Ostermeier, A. (2001). Completely derandomized self-adaptation in evolution strategies. *Evolutionary Computation* 9(2): 159–195.

Parameter setting. For the experiments, MA-LSCh-CMA applies BLX- α with $\alpha = 0.5$. The population size is 60 individuals and the probability of updating a chromosome by mutation is 0.125. The n_{ass} parameter associated with the negative assortative mating is set to 3. The value of the L G ratio, $r_{\text{L/G}}$, was set to 0.5, which represents an equilibrated choice. Finally, a value of $1e-8$ was assigned to the δ_{min} LS threshold.

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63




Figure 6: Rankings obtained by MA-LSCh-CMA instances with different I_{str} values

$I_{str} = 500$ is the best choice

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63




Figure 7: Percentages of LS chains with different lengths ($D = 10$)

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63




Figure 8: Percentages of LS chains with different lengths ($D = 30$)

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63




Figure 9: Percentages of LS chains with different lengths ($D = 50$)

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63

Comparison with State-of-the-Art MACOs

D	$R+$ (MA-LSCh-CMA)	$R-$ (DEahcSPX)	Critical value	Sig. differences?
10	135	75	52	No
30	169.5	40.5	52	Yes
50	176.5	33.5	52	Yes

Table 7: DEahcSPX versus MA-LSCh-CMA (Wilcoxon's test with p -value = 0.05)

Noman, N. and Iba, H. (2008). Accelerating differential evolution using an adaptive local search. *IEEE Transactions on Evolutionary Computation*. 12:1 (2008)107–125.

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63

Comparison with the Winner of the CEC2005

D	$R+$ (MA-LSCh-CMA)	$R-$ (G-CMA-ES)	Critical value ($p=0.05/p=0.1$)	Sig. dif.? ($p=0.05$)	Sig. dif.? ($p=0.1$)
10	32.5	177.5	52/60	Yes	Yes
30	139	71	52/60	No	No
50	154	56	52/60	No	Yes

Table 8: G-CMA-ES versus MA-LSCh-CMA (Wilcoxon's test with p -value = 0.05 and p -value=0.1)

Auger, A. and Hansen, N. (2005a). A restart CMA evolution strategy with increasing population size. In *Proc. of the 2005 IEEE Congress on Evolutionary Computation*, pages 1769-1776.

S. García, D. Molina, M. Lozano, F. Herrera, A Study on the Use of Non-Parametric Tests for Analyzing the Evolutionary Algorithms' Behaviour: A Case Study on the CEC'2005 Special Session on Real Parameter Optimization. *Journal of Heuristics*, [doi: 10.1007/s10732-008-9080-4](https://doi.org/10.1007/s10732-008-9080-4), 15 (2009) 617-644

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63

Comparison with the Other CEC2005 competitors

Algorithm	$R+$ (MA-LSCh-CMA)	$R-$ (CEC2005)	Critical value	Sig. differences?
BLX-GL50	92.5	117.5	52	No
BLX-MA	79	131	52	No
CoEvo	157	53	52	No
DE	122	88	52	No
DMS-L-PSO	54.5	155.5	52	No
EDA	98	112	52	No
K-PCX	128	82	52	No
L-SaDE	48.5	161.5	52	Yes
SPC-PNX	95	115	52	No

Table 9: Comparison of MA-LSCh-CMA with CEC2005 competitors for $D = 10$ (Wilcoxon's test with p -value = 0.05)

Algoritmos Meméticos: Adaptación LS

Adaptación de la Búsqueda Local

D. Molina, M. Lozano, C. García-Martínez, F. Herrera, **Memetic Algorithms for Continuous Optimization Based on Local Search Chains**. *Evolutionary Computation*, 18(1), 2010, 27–63

Comparison with the Other CEC2005 competitors

Algorithm	$R+$ (MA-LSCh-CMA)	$R-$ (CEC2005)	Critical value	Sig. differences?
BLX-GL50	166	44.5	52	Yes
BLX-MA	198	11.5	52	Yes
CoEvo	210	0	52	Yes
DE	199.5	10.5	52	Yes
K-PCX	174	36	52	Yes
SPC-PNX	169.5	40.6	52	Yes

Table 10: Comparison of MA-LSCh-CMA with CEC2005 competitors for $D = 30$ (Wilcoxon's test with p -value = 0.05)

Algoritmos Meméticos: Adaptación LS

Paquete en R (CRAN)



Journal of Statistical Software

December 2016, Volume 75, Issue 4.

doi: 10.18637/jss.v075.i04

Memetic Algorithms with Local Search Chains
in R: The Rmalschains Package

Christoph Bergmeir
Monash University

Daniel Molina
University of Cádiz

José M. Benítez
University of Granada

Package ‘Rmalschains’

November 29, 2016

<https://cran.r-project.org/web/packages/Rmalschains/index.html>

ALGORITMOS MEMÉTICOS

SUMARIO

- ¿Qué es un Algoritmo Memético?
- ¿Por qué hibridar? Los límites de los Algoritmos Evolutivos
- Algoritmos Meméticos: Introducción
- Sobre el Diseño de Algoritmos Meméticos
- Conclusiones

ALGORITMOS MEMÉTICOS

Comentarios finales

- Los AMs son técnicas de optimización que **explotan el conocimiento disponible** de un problema embebido en un modelo de evolución de poblaciones.
- No son un paradigma “purista” u “ortodoxo”. **Tienen muchos grados de libertad para el usuario.**
- Cuando se aborda el diseño de un AM efectivo para un cierto problema, hay que partir de la base de que **no existe un procedimiento sistemático para tal fin.**
- Han demostrado ser **más eficaces** que los AGs para diferentes problemas.

ALGORITMOS MEMÉTICOS

Bibliografía Básica

- P. Moscato, "Memetic Algorithms: A short introduction", *New Ideas in Optimization* (pp. 219-234), Corne D., Dorigo M., Glover F., McGraw-Hill-UK, 1999
- P. Moscato, C. Cotta, "A Gentle Introduction to Memetic Algorithms", *Handbook of Metaheuristics*, F. Glover, G. Kochenberger (eds.), pp. 105-144, Kluwer Academic Publishers, Boston MA, 2003
- P. Moscato, C. Cotta, "Una Introducción a los Algoritmos Memeticos", *Inteligencia Artificial. Revista Iberoamericana de IA*, No. 19, 2003, 131-148.
- W E Hart, N Krasnogor and J E Smith. "Memetic Evolutionary Algorithms", *Recent Advances in Memetic Algorithms*, Hart, William E.; Krasnogor, N.; Smith, J.E. (Eds.) 2005, 3-27.
- N. Krasnogor and J.E. Smith.
A tutorial for competent memetic algorithms: model, taxonomy and design issues.
IEEE Transactions on Evolutionary Computation 9(5):474- 488, 2005.
- Y.S. Ong and M.-H. Lim and N. Zhu and K.W. Wong.
Classification of Adaptive Memetic Algorithms: a Comparative Study
IEEE Transactions on System, Man. and Cybernetic. Part B. 36:1, 141-152, 2006.
- J. E. Smith. Coevolving Memetic Algorithms: A Review and Progress Report. IEEE Transactions on System, Man, and Cybernetics. Part B: Cybernetics 37:1, 2007, 6-17.

METAHEURÍSTICAS

2023 - 2024



- Tema 1. Introducción a las Metaheurísticas
- Tema 2. Modelos de Búsqueda: Entornos y Trayectorias vs Poblaciones
- Tema 3. Metaheurísticas Basadas en Poblaciones
- Tema 4: Algoritmos Meméticos
- Tema 5. Metaheurísticas Basadas en Trayectorias
- Tema 6. Metaheurísticas Basadas en Adaptación Social
- Tema 7. Aspectos Avanzados en Metaheurísticas
- Tema 8. Metaheurísticas Paralelas
- Tema 9. Modelos de IA Evolutivos. Aprendizaje Evolutivo

PRACTICA 4 – Hasta 5 ptos – Alternativa Examen (1 + 1.5 + 1 + 1.5)

1. **Elegir una MH (MHe) no estudiada en clase (Hasta 1) (Alternativamente hacer una propuesta original)**
 - A) Resumen (hasta 2-3 paginas)
 - B) **Presentación transparencias.** Transparencia: analizar componentes que provocan exploración vs componentes que provocan explotación. Analizar este equilibrio.
2. **Adaptar el uso de la MH a uno de los problemas de prácticas. Discutir cómo y hacer un estudio experimental comparando con los resultados de las prácticas 1 a 3 que se tengan. (Hasta 1) (Hasta 1.5 por dificultad)**
3. **Diseñar una propuesta de calidad (mejorando a MHe) Algoritmo híbrido memético (MHe + Local Search, opción u otra hibridación) (Hasta 1)**
4. **Plantear mejoras sobre el comportamiento/diseño de MHe (Hasta 1.5 con estudio experimental):**
 - Modificar/introducir componentes para mejorar el equilibrio diversidad-convergencia (ej. CHC, GADEGD, ...)
 - Adaptar el algoritmo para que obtenga múltiples soluciones.

Nuevos modelos bioinspirados para la optimización de parámetros – Estado del arte

Revisión de propuestas de Metaheurísticas

<https://arxiv.org/abs/2002.08136>

Published: 05 July 2020

Comprehensive Taxonomies of Nature- and Bio-inspired Optimization: Inspiration Versus Algorithmic Behavior, Critical Analysis Recommendations

Daniel Molina, Javier Poyatos, Javier Del Ser, Salvador García, Amir Hussain & Francisco Herrera

Cognitive Computation 12, 897–939(2020) | Cite this article

6 Citations | 0 Altmetric | Metrics

arXiv.org > cs > arXiv:2002.08136

Computer Science > Artificial Intelligence

Comprehensive Taxonomies of Nature- and Bio-inspired Optimization: Inspiration versus Algorithmic Behavior, Critical Analysis and Recommendations

Daniel Molina, Javier Poyatos, Javier Del Ser, Salvador García, Amir Hussain, Francisco Herrera

(Submitted on 19 Feb 2020 (v1), last revised 20 Feb 2020 (this version, v2))

In recent years, a great variety of nature- and bio-inspired algorithms has been reported in the literature. This algorithm observed in Nature in order to efficiently address complex optimization problems. In the last years the number of bio-grown considerably, reaching unprecedented levels that dark the future prospects of this field of research. This paper comprehensive, principle-based taxonomies that allow researchers to organize existing and future algorithmic develo different criteria: the source of inspiration and the behavior of each algorithm. Using these taxonomies we review mo nature-inspired and bio-inspired algorithms, and proposals falling within each of these categories are examined, lead similarities between them, and the identification of the most similar classical algorithm for each reviewed paper. From often found between the natural inspiration of an algorithm and its behavior. Furthermore, similarities in terms of beh: what is claimed in their public disclosure: specifically, we show that more than one-third of the reviewed bio-inspired : Grounded on the conclusions of our critical analysis, we give several recommendations and points of improvement fc growing research field.

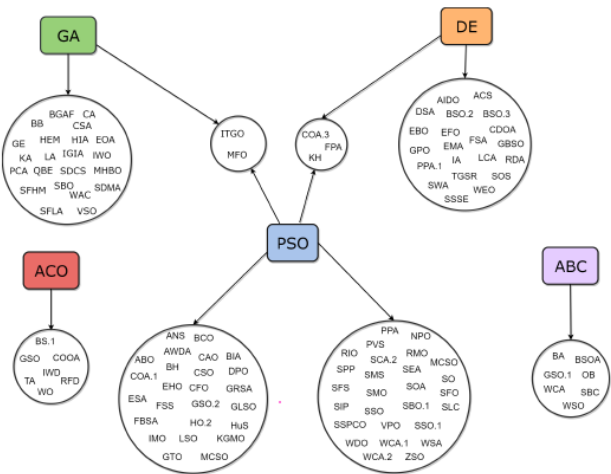


Figure 6: Classification of proposals by its original algorithm.

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

- Usaremos benchmark “CEC 2017 Special Session and Competition on Single Objective Bound Constrained Real-Parameter Numerical Optimization”.
- 30 funciones, distinto nivel de complejidad.
- Distintos valores de dimensión: 10, 30, 50 (no 100).
- Criterio de parada: $10.000 * dimension$.
- Rango de todas las funciones: $[-100, 100]$.
- Se ejecuta cada una X veces para calcular la media (usamos $T=10$, por reducir tiempos, el estándar son 50).
- Se mide el error con respecto al óptimo ($fun * 100$): 100 para f_1 , 200 f_2 , ...
- Se calcula el error cada cierto % de evaluaciones: 1%, 2%, ..., 10%, 20%, ...

G. Wu, R. Mallipeddi, P. N. Suganthan, Problem definitions and evaluation criteria for the CEC 2017 competition and special session on constrained single objective real-parameter optimization, Tech. rep., Nanyang Technological University, Singapore (2016).

3/16

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

- Código actualizado en <https://github.com/dmolina/cec2017real/>.
- Disponible en C++, con wrapper para Python.
- Se puede compilar como librería, o dentro del proyecto.
- Ficheros:
 - *cec17_test_func.c*: fichero original del benchmark.
 - *cec17.c*: con las funciones del API simplificado.
 - *input_data*: debe estar en el directorio donde se ejecute el binario.
 - *extract.py*: script en Python para agrupar los resultados.

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

- A) Proponer una MH nueva inspirada en algún fenómenos de la naturaliza (pasos 1 a 3)
- B) Analizar una MH reciente (Mhe) <https://arxiv.org/abs/2002.08136>

1. Parte I. (Hasta 1.0)

- A) Resumen (hasta 2-3 paginas)
- B) Presentación transparencias

2. Parte II. (Hasta 1.5 ptos) Trabajar con la competición CEC2017 y utilizar el software presentado por Daniel Molina para el análisis de resultados <https://tacolab.org/>.

Select Benchmark

Select the benchmark used for comparison: CEC2017 ▼

CEC'2017 Real-Parameter Optimization

Benchmark for the Real-Parameter Optimization competitions.

Select the dimension value: ▼

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

3. Diseñar una propuesta de mejora con una hibridación Ej. Algoritmo híbrido memético (MHe + Local Search, u otra hibridación) (Hasta 1 pto.), y hacer el estudio experimental comparándolo con el software <https://tacolab.org/>.
4. Plantear mejoras sobre el comportamiento/diseño de la MHe (Hasta 1.5 ptos. con estudio experimental)

Hay que entregar una memoria completa de la práctica, tal como se hace en las prácticas de clase.

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

Cuestiones

- **¿Cuáles son los criterios que se van a utilizar a la hora de calificar la práctica alternativa?**

Se tienen 4 bloques y en cada uno se evaluará el trabajo realizado, que se ajuste a lo solicitado y la calidad del estudio experimental y su análisis. En el bloque 1 se analiza la calidad de la descripción, en los bloques 2 y 3 el estudio experimental y análisis, y en el

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

Cuestiones

- ¿Hay que superar alguna metaheurística tomada como referencia?

No necesariamente, la naturaleza de la MHe condicionará la calidad del resultado.

- ¿Podrían subir algún guión especificando qué hay que entregar exactamente?

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

Cuestiones

- ¿Cuando hay que avisarle (si es que hace falta) de cuál será nuestra metaheurística inventada?

Para indicar que MHe se va a utilizar (original o del documento mencionado) se tiene plazo hasta final de Mayo, y se necesita confirmación del profesor para evitar un uso excesivo de la misma MHe. Puede no entregarse la práctica e ir al examen, avisando con 48 horas de antelación a la fecha del examen.

PRACTICA 4 – Hasta 5 ptos

Alternativa Examen

¿Se puede plantear un estudio alternativo?

Si, se puede hacer un estudio en un campo de aplicación concreto.

Ejemplo: Evolución de modelos de Deep Learning

Real, Esteban, et al. “Large-scale evolution of image classifiers.” arXiv preprint 2016, ICML. 2017.